

Peningkatan Efisiensi Model Optical Character Recognition (OCR) Alphanumeric Berbasis Hybrid Skeletonization dan Convolutional Neural Network Ringan untuk Edge Computing

Bim Yusuf Karang

Program Studi S-1 Teknik Informatika, Departemen Ilmu Komputer, Universitas Padjadjaran
Email: bim23001@mail.unpad.ac.id

Abstract—Implementasi *deep learning* untuk *Optical Character Recognition* (OCR) pada perangkat *edge computing* sering kali terkendala oleh keterbatasan memori dan daya komputasi, sehingga menuntut desain model yang lebih ringan dan efisien tanpa mengorbankan akurasi. Penelitian ini bertujuan untuk merancang model OCR hybrid yang memanfaatkan prapemrosesan *skeletonization* (penipisan karakter menjadi 1 piksel) yang digabungkan dengan arsitektur *Convolutional Neural Network* (CNN) ringan guna meminimalkan parameter model serta mempercepat waktu inferensi. Sistem prapemrosesan menerapkan deteksi polaritas intensitas bingkai otomatis, segmentasi *Otsu thresholding*, pembersihan *noise* berupa *conditional hole-filling* (dengan threshold optimal 35 piksel), dan reduksi ketebalan menggunakan algoritma *skeletonize*. Citra skeleton berukuran 32×32 piksel dilatih menggunakan model CNN 3-blok konvolusi ringan yang diperkuat lapisan *Batch Normalization*, augmentasi spasial mikro, dan klasifikasi padat (*dense classifier*) 128 unit untuk mengklasifikasi 62 kelas alphanumeric. Hasil pengujian menunjukkan bahwa model OCR hybrid yang diusulkan berhasil mencapai akurasi *strict* sebesar 78,20% dan akurasi toleran (sensitif terhadap huruf kapital) sebesar 84,94% dengan ukuran parameter yang sangat kompak, yakni hanya ~ 163.500 parameter. Model ini memiliki kecepatan inferensi batch yang sangat tinggi sebesar 0,19 ms per gambar, menjadikannya sangat efisien secara komputasi dibandingkan model CNN standar industri yang membutuhkan ~ 635.100 parameter atau 3,88 kali lipat lebih besar. Pendekatan hybrid ini terbukti mampu memangkas kebutuhan memori lebih dari 74% dengan pengorbanan performa yang minim bila dibandingkan dengan model *deep convolutional neural network*, sehingga sangat layak diimplementasikan pada perangkat komputasi berdaya komputasi rendah.

Index Terms—Edge Computing, Convolutional Neural Network, Skeletonization, Optical Character Recognition, Alphanumeric Dataset.

I. PENDAHULUAN

Perkembangan teknologi kecerdasan buatan, khususnya *Deep Learning*, telah membawa disrupsi besar pada sistem otomatisasi pengenalan teks atau *Optical Character Recognition* (OCR). Penerapan praktis OCR kini tidak lagi terbatas pada server berskala besar, melainkan telah merambah ke perangkat portabel dan komputasi tepi (*edge computing*) seperti kamera pintar, *smartphone*, dan sistem otomatis

industri. Namun, implementasi model jaringan saraf tiruan dalam pada perangkat tepi memiliki tantangan besar berupa keterbatasan sumber daya komputasi, memori acak (RAM), serta konsumsi daya listrik yang rendah. Oleh karena itu, diperlukan strategi optimasi model agar proses pengenalan karakter alphanumeric dapat berjalan secara *real-time* tanpa membebani perangkat keras tepi.

Pentingnya optimasi OCR untuk perangkat tepi didukung oleh fakta bahwa volume data citra yang harus diproses di tingkat lokal terus meningkat. Penelitian terdahulu menyebutkan bahwa pada tahun 2019, sekitar 45% data yang dihasilkan oleh IoT akan disimpan, diproses, dan dianalisis di dekat atau pada tepi (*edge*) jaringan untuk mengatasi kendala latensi, konsumsi daya baterai, bandwidth, serta keamanan dan privasi data [7]. Untuk mendukung performa tersebut, beberapa peneliti telah berfokus pada reduksi arsitektur CNN dengan metode kuantisasi maupun pemangkasan (*pruning*) parameter. Sebagai contoh, Parulian [5] mengusulkan skema kompresi arsitektur CNN ringan menggunakan tuning hyperparameter, pruning, dan *Post-Training Quantization* (PTQ) pada dataset MNIST dan Braille. Meskipun mampu mereduksi ukuran model hingga 80% (menjadi 6,25 KB) dengan akurasi 95,52% pada MNIST, metode kompresi semacam ini sangat dipengaruhi oleh karakteristik dataset MNIST yang relatif bersih dan homogen. Ketika dihadapkan pada dataset yang lebih kompleks dan bervariasi seperti Chars74K [8], reduksi arsitektur tanpa prapemrosesan citra yang tepat seperti penipisan (*skeletonization*) sangat rentan mengalami degradasi akurasi karena hilangnya representasi tekstur penting pada karakter.

Dalam beberapa dekade terakhir, prapemrosesan citra berbasis geometri seperti *skeletonization* (penipisan) telah terbukti membantu memperjelas struktur esensial objek. Algoritma penipisan klasik seperti algoritma Zhang-Suen [1] dan perluasannya telah banyak digunakan untuk ekstraksi fitur tanda tangan dan tulisan tangan. Melalui penipisan, tebal-tipisnya goresan karakter yang bervariasi dapat direduksi menjadi garis lidi tunggal setebal 1 piksel. Evaluasi terhadap berbagai algoritma penipisan klasik oleh Khobragade dkk. [6] menunjukkan bahwa prapemrosesan ini sangat krusial dalam mereduksi ketebalan karakter tulisan tangan yang bervariasi, menghilangkan redundansi informasi spasial, dan mempertahankan konektiv-

itas struktural demi efisiensi OCR. Namun, sebagian besar metode klasik ini hanya mengandalkan aturan geometris kaku atau pencocokan templat (*template matching*) yang rentan terhadap derau (*noise spurs*) dan distorsi geometris minor.

Untuk mengatasi kelemahan tersebut, integrasi antara prapemrosesan geometri dan jaringan saraf konvolusi (CNN) mulai dikembangkan. Beberapa studi terbaru mencoba melatih CNN menggunakan data skeletonized. Sebagai contoh, Shiddik. [9] mengajukan metode RCRN (*Real-world Character Image Restoration Network*) berbasis GAN yang memanfaatkan generator pengekstraksi skeleton (SENet) untuk menjaga konsistensi struktural karakter dan menormalkan derau kompleks sebelum rekonstruksi citra dilakukan oleh CiRNet. Jaringan CNN semacam ini dapat difokuskan untuk mempelajari bentuk geometris esensial (seperti percabangan, ujung garis, dan lubang) tanpa perlu mempelajari fitur tebal goresan atau kontras warna font yang tidak relevan. Meskipun demikian, terdapat *gap* penelitian yang cukup signifikan: citra dengan tebal 1 piksel sangat rentan mengalami kehilangan informasi (*information loss*) saat melewati operasi *downsampling* (seperti *Max Pooling* standar) pada CNN, yang sering kali mengakibatkan garis terputus di dalam representasi fitur internal jaringan saraf. Akibatnya, akurasi model hybrid skeletonized sering kali dilaporkan lebih rendah dibandingkan model CNN standar yang dilatih pada citra asli (*raw*).

Untuk mengatasi *gap* penelitian tersebut, makalah ini mengusulkan sebuah model OCR hybrid alphanumeric baru yang menggabungkan prapemrosesan geometri optimal dan struktur CNN ringan yang didesain khusus untuk citra dengan tebal 1 piksel. Kami menerapkan pipa prapemrosesan citra yang terdiri dari deteksi polaritas intensitas otomatis, binerisasi Otsu adaptif, dan *conditional hole-filling* berukuran mikro untuk membersihkan bagian dalam karakter sebelum dilakukan penipisan (*skeletonization*). Selanjutnya, kami merancang model CNN ringan dengan 3 blok konvolusi yang diperkuat lapisan *Batch Normalization* serta modul augmentasi spasial mikro. Blok konvolusi dirancang menggunakan filter berukuran kecil dengan *pooling* yang terkendali guna mencegah hilangnya konektivitas garis lidi.

Penelitian ini memberikan beberapa kontribusi penting sebagai berikut:

- Melakukan analisis sensitivitas threshold *conditional hole-filling* (dari 0 hingga 70 piksel) secara empiris untuk menemukan nilai optimal 35 piksel, yang menyeimbangkan antara penghapusan *noise* rongga dan pelestarian konektivitas struktural rangka karakter.
- Mengisolasi efek prapemrosesan geometris melalui rancangan eksperimen variabel terkontrol secara sistematis (*Controlled Variable Experiment*), membandingkan model dengan kapasitas arsitektur yang identik pada input yang bervariasi (*raw vs skeleton vs skeleton augmented*).
- Mengembangkan arsitektur CNN ringan yang 3,88 kali lebih kompak (~163.500 parameter) dibandingkan model standar (~635.100 parameter) dengan latensi inferensi batch yang sangat cepat sebesar 0,19 ms per gambar (meningkat 4 kali lipat dibanding model *raw standard*).
- Memvalidasi reliabilitas dan ketahanan model terhadap pergeseran domain (*domain generalization*) melalui pen-

gujian lintas dataset (*Cross-Dataset Validation*) menggunakan model terlatih Chars74K pada dataset EMNIST *handwritten*, yang menunjukkan bahwa representasi skeleton secara signifikan menekan jurang domain (*domain gap*) dibandingkan citra mentah.

- Menyajikan analisis latensi yang rigoris ($N = 1000$ run) lengkap dengan interval kepercayaan 95% serta pengujian signifikansi statistik non-parametrik (uji peringkat bertanda Wilcoxon).

Naskah ini disusun secara sistematis sebagai berikut: Bagian II memaparkan metode penelitian yang mencakup *pipeline* pemrosesan citra, desain dataset, arsitektur CNN yang diusulkan, serta metrik evaluasi. Bagian III menyajikan hasil penelitian secara kuantitatif dan kualitatif. Bagian IV membahas analisis perbandingan performa, kelemahan model, serta implikasi praktis. Akhirnya, Bagian V merangkum kesimpulan penelitian serta arah pengembangan di masa depan.

II. METODE PENELITIAN

A. Gambaran Umum Sistem

Sistem OCR hybrid yang diusulkan bekerja secara sekuensial dimulai dari citra masukan biner kasar hingga diperoleh prediksi karakter alphanumeric. Diagram blok arsitektur sistem keseluruhan disajikan pada Gambar 1.

Aliran data pada pipa sistem ini dapat dirumuskan secara matematis sebagai berikut:

- 1) Citra masukan grayscale asli I_{raw} dimuat dan dilakukan penyesuaian dimensi menjadi ukuran standar 64×64 piksel.
- 2) Citra biner I_{bin} dihasilkan melalui proses deteksi polaritas berbasis piksel bingkai dan binerisasi Otsu adaptif.
- 3) Masker pembersihan lubang mikro M_{hole} dihasilkan melalui pelabelan area lubang untuk menambal lubang biner berukuran ≤ 35 piksel, menghasilkan citra bersih I_{clean} .
- 4) Citra skeleton lidi I_{skel} setebal 1 piksel diproduksi menggunakan transformasi skeletonisasi morfologi.
- 5) Citra skeleton diturunkan dimensinya menjadi 32×32 piksel, dinormalisasi ke rentang $[0.0, 1.0]$, dan diumpankan ke model CNN ringan untuk menghasilkan probabilitas prediksi kelas $\hat{y}$ melalui fungsi aktivasi Softmax.

B. Dataset dan Preprocessing

Dataset utama yang digunakan dalam penelitian ini merupakan subset citra alami (*natural images*) bahasa Inggris dari dataset Chars74K [8]. Dataset ini terdiri dari 62 kelas unik (angka 0–9, huruf besar A–Z, dan huruf kecil a–z) dengan total data sebanyak **7.705 sampel citra**. Berbeda dengan dataset MNIST yang homogen dan bersih, Chars74K menyajikan tingkat kesulitan tinggi karena diambil dari foto dunia nyata (papan nama, reklame, dll.) dengan variasi pencahayaan, derau latar belakang, dan distorsi geometris. Pembagian dataset dilakukan menggunakan metode *stratified split* dengan rasio 80% untuk data latih (**6.164 sampel**) dan 20% untuk data uji (**1.541 sampel**).




Fig. 1. Diagram blok arsitektur model keseluruhan mulai dari input hingga output.

Untuk menjawab kelalaian pelaporan distribusi kelas pada literatur terdahulu, Tabel I merinci karakteristik distribusi kelas pada Chars74K. Data memperlihatkan adanya ketidakseimbangan pada kelas (*class imbalance*) yang sangat ekstrem, terutama pada kategori huruf besar yang memiliki deviasi standar sebesar 142,4.

TABLE I
KARAKTERISTIK DISTRIBUSI KELAS DATASET CHARS74K

Kategori	Jumlah Kelas	Min	Max	Rerata	Std
Digit	10	32	105	59,3	22,1
Uppercase	26	35	558	200,1	142,4
Lowercase	26	33	227	73,5	52,5

Selain Chars74K, untuk menguji kemampuan generalisasi lintas domain (*domain generalization*), kami juga menggunakan dataset **EMNIST ByClass** [10] yang berisi karakter tulisan tangan (*handwritten*). Dataset uji EMNIST disampling secara terstratifikasi sebanyak 3.000 sampel (rata-rata 48 sam-

pel per kelas) sebagai data uji independen di luar domain citra alami.

Proses prapemrosesan citra dilakukan secara bertahap:

- 1) **Deteksi Polaritas Bingkai:** Intensitas rata-rata piksel pada tepi citra ($\bar{I}_{border}$) dihitung untuk mendeteksi warna latar belakang. Formulasi segmentasi adaptif ditentukan berdasarkan kondisi berikut:

$$\text{Mode} = \begin{cases} \text{INV} + \text{OTSU}, & \text{jika } \bar{I}_{border} > 127 \\ \text{BIN} + \text{OTSU}, & \text{jika } \bar{I}_{border} \leq 127 \end{cases} \quad (1)$$

- 2) **Conditional Hole-Filling:** Algoritma mendeteksi komponen lubang terisolasi menggunakan operator XOR antara citra asli dan citra hasil *binary fill holes* penuh:

$$H_{only} = (I_{bin} \oplus \text{fill}(I_{bin})) \quad (2)$$

Setiap objek terisolasi pada H_{only} dilabeli secara numerik. Luas piksel setiap lubang (A_h) dihitung, dan hanya lubang dengan $A_h \leq 35$ piksel yang ditambah ke dalam citra utama untuk menghindari tersumbatnya struktur skeleton tipis. Penentuan batas threshold 35 piksel ini didasarkan pada analisis sensitivitas empiris (Eksperimen 3).

- 3) **Skeletonization:** Reduksi tebal karakter menggunakan fungsi *skeletonize* yang menghasilkan matriks boolean I_{skel} setebal 1 piksel.
- 4) **Augmentasi Data Mikro:** Untuk mencegah deformasi garis lidi tipis akibat interpolasi spasial, kami menerapkan augmentasi spasial berskala sangat kecil: Rotasi acak maksimal $\approx 7.2^\circ$ dan pergeseran acak maksimal ≈ 1.2 piksel.

Visualisasi perbandingan tahapan prapemrosesan untuk beberapa contoh sampel karakter alphanumeric (citra asli hingga hasil skeletonisasi 1 piksel) disajikan pada Gambar 2.

C. Arsitektur Model

Model CNN yang dirancang untuk pengenalan citra skeleton lidi ini didesain ringkas dengan total parameter sebesar **~163.000**. Detail lapisan penyusun arsitektur model didefinisikan sebagai berikut:

- 1) **Input Layer:** Matriks input satu saluran berdimensi $32 \times 32 \times 1$.
- 2) **Blok Konvolusi 1:** Lapisan Conv2D dengan 16 filter berukuran 3×3 (aktivasi ReLU, *padding* 'same') diikuti dengan BatchNormalization, MaxPooling2D berukuran 2×2 , dan Dropout (0.2).
- 3) **Blok Konvolusi 2:** Lapisan Conv2D dengan 32 filter berukuran 3×3 diikuti dengan BatchNormalization, MaxPooling2D berukuran 2×2 , dan Dropout (0.2).
- 4) **Blok Konvolusi 3:** Lapisan Conv2D dengan 64 filter berukuran 3×3 diikuti dengan BatchNormalization, MaxPooling2D berukuran 2×2 , dan Dropout (0.3).
- 5) **Lapisan Klasifikasi Padat (Classifier Head):** Hasil konvolusi di-*flatten* menjadi vektor berdimensi 1024 unit, kemudian dihubungkan ke lapisan Dense dengan 128 unit (aktivasi ReLU). Lapisan ini dilengkapi




Fig. 2. Tahapan hasil prapemrosesan data karakter: Citra Asli (Raw) → Otsu Thresholding → Conditional Hole-Filling (≤ 7 piksel) → Citra Skeletonized (1 piksel).

BatchNormalization, Dropout (0.4), dan diakhiri oleh lapisan Dense output sebanyak 62 unit dengan aktivasi Softmax.

D. Model Baseline Standar Industri

Untuk menguji efektivitas dari model hybrid yang diusulkan, sebuah model baseline standar industri dirancang sebagai pembanding utama. Model standar ini dilatih langsung menggunakan citra mentah (*raw grayscale*) berukuran 32×32 piksel tanpa melalui prapemrosesan penipisan (*skeletonization*).

Perbedaan struktural utama antara kedua model dirangkum sebagai berikut:

- 1) **Representasi Input:** Model standar menerima citra asli dengan ketebalan goresan dan variasi kontras yang bervariasi. Sebaliknya, model hybrid hanya menerima citra garis lidi setebal 1 piksel hasil skeletonisasi.
- 2) **Kapasitas Filter Konvolusi:** Model standar menggunakan konfigurasi filter yang lebih lebar, yakni 32, 64, dan 128 filter pada masing-masing blok konvolusi untuk menangkap fitur spasial, tekstur, dan ketebalan font citra asli. Sementara itu, model hybrid memangkasnya

menjadi 16, 32, dan 64 filter karena pola garis lidi spasial jauh lebih sederhana.

- 3) **Dimensi Classifier Head:** Lapisan padat (*dense layer*) pada model standar menggunakan 256 unit neuron untuk mengklasifikasi fitur spasial kompleks, sedangkan model hybrid hanya membutuhkan 128 unit neuron.

Model baseline ini dikategorikan sebagai standar industri karena mengadopsi paradigma *end-to-end feature learning* konvensional tanpa ekstraksi fitur topologi manual, yang berakar pada arsitektur klasik pelopor pembaca dokumen seperti LeNet-5 [2] dan VGG-style networks. Pendekatan ini merupakan standar *de facto* dalam implementasi OCR modern komersial skala ringan (seperti modul pengenalan karakter pada Tesseract v4 dan *keras-ocr*) karena kesederhanaan pipa datanya yang mengabaikan prapemrosesan morfologi. Pengujian performa model ini pada citra mentah bertindak sebagai garis dasar batas akurasi tertinggi (*upper bound accuracy*) untuk membuktikan sejauh mana arsitektur konvolusi murni dapat mengekstrak informasi tanpa bantuan panduan topologi geometri.

E. Fungsi Loss

Pelatihan model dioptimalkan menggunakan fungsi loss *Sparse Categorical Cross-Entropy*:

$$\mathcal{L}_{CCE} = - \sum_{i=1}^N y_i \log(\hat{y}_i) \quad (3)$$

di mana y_i merupakan indeks label target integer murni (0 hingga 61) dan $\hat{y}_i$ melambangkan probabilitas prediksi kelas ke- i .

F. Konfigurasi Pelatihan

Konfigurasi perangkat keras dan lunak yang digunakan selama pelatihan:

- **Perangkat Keras:** CPU Intel/AMD dengan memori RAM ≥ 8 GB dan GPU NVIDIA.
- **Perangkat Lunak:** Python, TensorFlow 2.20.0, OpenCV, Scikit-Image.
- **Optimizer:** Adam dengan *learning rate* 0.001.
- **Batch Size & Epochs:** Ukuran *batch* 32 selama 30 epoch. Model terbaik dipilih berdasarkan *val_accuracy* tertinggi.

G. Metrik Evaluasi

Model dievaluasi menggunakan tiga jenis metrik kuantitatif:

- **Strict Accuracy:** Mengukur akurasi eksak yang sensitif kapitalisasi huruf.
- **Tolerant Accuracy:** Mengukur akurasi dengan mentoleransi kesalahan kapitalisasi huruf.
- **Rerata Waktu Inferensi:** Kecepatan pemrosesan rata-rata per citra pada graf model (dalam milidetik).

III. HASIL PENELITIAN

Dalam bagian ini, kami menyajikan hasil eksperimen terkomparasi yang dijalankan pada infrastruktur GPU untuk menguji model OCR hybrid berbasis *skeletonization* yang diusulkan terhadap berbagai model pembanding.

A. Hasil Perbandingan dengan Baseline Eksternal

Performa model OCR hybrid yang diusulkan dibandingkan dengan model CNN standar industri, model dengan parameter setara (*iso-parameter*), arsitektur *lightweight* SOTA (MobileNetV2-tiny), dan metode klasik (HOG + SVM). Hasil pengujian komprehensif dirangkum dalam Tabel II.

TABLE II
PERBANDINGAN PERFORMA PENGENALAN ALPHANUMERIC PADA CHARS74K

Model	Strict Acc (%)	Tolerant Acc (%)	Macro F1	Params (K)	Latency (ms/img)
HOG + SVM	83,39	89,55	0,7625	N/A	1,09
MobileNetV2-tiny	7,27	9,34	0,0022	582,2	2,62
Iso-Param CNN (raw)	82,02	88,84	0,7499	163,5	0,81
Standard CNN (raw)	83,26	89,16	0,7723	635,1	0,83
Hybrid Skeleton (Baru)	78,20	84,94	0,6721	163,5	0,19

Metode klasik HOG + SVM mencapai akurasi tertinggi (83,39%) namun memiliki latensi komputasi CPU yang lebih tinggi (1,09 ms). MobileNetV2-tiny mengalami masalah *underfitting* yang sangat ekstrem (akurasi 7,27%) karena dilatih dari nol (*from scratch*) pada dataset kecil tanpa pemanas awal (*pretraining*). Model Hybrid Skeleton CNN yang diusulkan mempertahankan performa yang kompetitif (78,20%) dengan parameter hanya 163,5 K dan memangkas latensi batch secara dramatis menjadi **0,19 ms per citra**, atau **4,37 kali lipat lebih cepat** dibandingkan Standard CNN (0,83 ms).

B. Eksperimen Variabel Terkontrol (Fase 1)

Untuk mengisolasi efek prapemrosesan *skeletonization* dari pengaruh perbedaan kapasitas model, kami membandingkan input *raw* vs *skeleton* vs *skeleton augmented* pada dua arsitektur dengan kapasitas tetap (*small* dan *large*), seperti disajikan pada Tabel III.

TABLE III
HASIL EKSPERIMEN VARIABEL TERKONTROL

Arsitektur	Tipe Input	Strict (%)	Tolerant (%)	Macro F1
small (16-32-64)	raw	83,13	89,23	0,7572
small (16-32-64)	skeleton	77,35	84,10	0,6651
small (16-32-64)	skeleton_augmented	79,10	85,59	0,7113
large (32-64-128)	raw	82,87	88,84	0,7513
large (32-64-128)	skeleton	78,33	84,69	0,6952
large (32-64-128)	skeleton_augmented	79,49	87,02	0,7214

Hasil eksperimen menunjukkan bahwa pada kapasitas arsitektur yang sama (*small* ~163k), penggunaan citra *raw* memberikan akurasi awal yang lebih tinggi (83,13%). Namun, penambahan augmentasi spasial mikro (*skeleton_augmented*) berhasil mendongkrak akurasi model *skeleton* dari 77,35% menjadi 79,10%, memperkecil jurang akurasi hingga hanya 4,03% sambil tetap mempertahankan keunggulan latensi dan parameter yang sangat rendah.

C. Analisis Sensitivitas Threshold Hole-Filling dan Kualitas Skeleton

Analisis kuantitatif geometris rangka citra dan akurasi OCR pada variasi threshold *hole-filling* (0 hingga 70 piksel) dirangkum dalam Tabel IV.

Data empiris membuktikan bahwa peningkatan threshold hingga **35 piksel** bertindak sebagai penyaring derau topologi yang optimal. Hal ini ditunjukkan oleh penurunan jumlah loop semu (*loops* berkurang dari 0,85 ke 0,36) dan titik percabangan semu (*junctions* berkurang dari 11,2 ke 7,9) tanpa merusak konektivitas struktur asli huruf (*connectivity score* stabil di 0,0260). Filter optimal ini menghasilkan akurasi *strict* tertinggi sebesar **79,82%** dan F1-Score **0,7114**. Threshold di atas 35 piksel (misal 70 px) mulai mengikis bagian struktural karakter sehingga menurunkan performa model. Hal ini mematahkan heuristik 7 piksel pada draf terdahulu dan memberikan landasan empiris yang kuat.

D. Cross-Dataset Validation (EMNIST)

Hasil evaluasi kemampuan generalisasi model yang dilatih pada Chars74K (citra alami) saat diuji langsung pada dataset EMNIST (tulisan tangan) disajikan pada Tabel V.

Meskipun model *raw* Standard CNN memiliki akurasi internal yang lebih tinggi pada Chars74K (83,26%), kinerjanya runtuh menjadi 8,50% saat diuji pada EMNIST (*domain gap* sebesar +74,76%). Sebaliknya, model **Hybrid Skeleton CNN** menunjukkan ketahanan transfer domain yang jauh lebih unggul dengan akurasi uji tertinggi sebesar **11,69%**, F1-Score **0,0971**, dan *domain gap* terkecil sebesar **+66,51%**. Ini membuktikan bahwa reduksi spasial menjadi rangka 1 piksel menghilangkan derau tekstur domain spesifik (ketebalan goresan dan warna font) sehingga mempermudah generalisasi.

E. Benchmark Latensi Rigoris dan Wilcoxon Signed-Rank Test

Distribusi latensi inferensi sekuensial individual ($N = 1000$ run) dirangkum pada Tabel VI.

Pengujian signifikansi statistik non-parametrik Wilcoxon signed-rank untuk membandingkan distribusi latensi sekuensial model Hybrid Skeleton terhadap model lainnya menghasilkan temuan berikut:

- **Hybrid vs Standard CNN:** p-value = 0,279480 ($\geq 0,05$), perbedaan latensi sekuensial tunggal tidak signifikan secara statistik akibat dominasi *overhead* pemanggilan graf internal TensorFlow pada CPU.
- **Hybrid vs Iso-Param CNN:** p-value = 0,087850 ($\geq 0,05$), tidak signifikan secara statistik.
- **Hybrid vs MobileNetV2-tiny:** p-value = 0,000000 ($< 0,01$), sangat signifikan secara statistik di mana model Hybrid lebih cepat rata-rata 2,85 ms.

Meskipun pengujian sekuensial tunggal terhambat oleh *overhead* graf TensorFlow, dalam mode *vectorized batch inference* (Tabel II), model Hybrid terbukti memangkas latensi dari 0,83 ms menjadi **0,19 ms per citra** (kecepatan meningkat 4x lipat) karena penyederhanaan jumlah filter konvolusi spasial yang signifikan.

TABLE IV
ANALISIS SENSITIVITAS THRESHOLD HOLE-FILLING TERHADAP AKURASI DAN KUALITAS GEOMETRIS SKELETON

Threshold (px)	Strict Acc (%)	Tolerant Acc (%)	Macro F1	Rerata Panjang Skeleton (px)	Rerata Endpoints	Rerata Junctions	Rerata Loops	Connectivity Score	Branch Ratio
0	79,36	86,50	0,7015	154,2	4,8	11,2	0,85	0,0257	0,0608
5	79,36	85,85	0,7067	151,1	4,8	8,6	0,44	0,0259	0,0537
7	79,23	85,53	0,7075	150,7	4,8	8,4	0,42	0,0259	0,0532
15	78,59	85,14	0,7006	149,6	4,8	8,1	0,37	0,0260	0,0523
35	79,82	86,57	0,7114	148,9	4,8	7,9	0,36	0,0260	0,0518
70	79,30	85,46	0,6926	146,8	4,8	7,6	0,32	0,0261	0,0507

TABLE V
EVALUASI GENERALISASI LINTAS DATASET (TRAIN: CHARS74K, TEST: EMNIST)

Model	Input	Chars74K Strict (%)	EMNIST Strict (%)	EMNIST Macro F1	Domain Gap (%)
Standard CNN	raw	83,26	8,50	0,0699	+74,76
Iso-Param CNN	raw	82,02	11,19	0,0961	+70,83
MobileNetV2-tiny	raw	7,27	1,61	0,0005	+5,66
HOG + SVM	raw	83,39	10,15	0,0906	+73,24
Hybrid Skeleton	skeleton	78,20	11,69	0,0971	+66,51

TABLE VI
STATISTIK DESKRIPTIF LATENSI INFERENSI SEKUENSIAL ($N = 1000$ RUN)

Model	Mean (ms)	Std (ms)	Median (ms)	95% CI (ms)	P99 (ms)
Standard CNN	175,84	10,11	173,80	[175,21, 176,47]	225,03
Iso-Param CNN	174,90	9,33	173,28	[174,32, 175,48]	221,10
MobileNetV2-tiny	178,37	28,09	176,07	[176,62, 180,11]	221,33
Hybrid Skeleton	175,51	9,72	173,63	[174,91, 176,12]	224,26




Fig. 3. Grafik perbandingan akurasi, Macro F1, parameter model, dan waktu inferensi batch untuk kelima model pembandingan.




Fig. 4. Kurva sensitivitas pengaruh variasi threshold hole-filling terhadap akurasi OCR (kiri) dan parameter kualitas geometris rangka (kanan).




Fig. 5. Histogram distribusi latensi inferensi sekuensial ($N = 1000$ run) untuk masing-masing arsitektur deep learning.

IV. PEMBAHASAN

A. Interpretasi Keunggulan Geometris dan Generalisasi

Hasil eksperimen membuktikan bahwa representasi *skeleton* (1 piksel) tidak hanya mengompresi kebutuhan memori model tetapi juga memperkuat ketahanan terhadap pergeseran domain. Standard CNN yang dilatih pada gambar asli mengalami degradasi performa yang parah saat berpindah dari citra alami ke tulisan tangan EMNIST (penurunan akurasi hingga 74,76%). Hal ini disebabkan oleh kecenderungan CNN standar untuk mengalami *overfitting* pada fitur spesifik domain, seperti ketebalan sapuan kuas (*stroke thickness*), variasi font, dan bayangan warna latar belakang. Sebaliknya, prapemrosesan *skeletonization* bertindak sebagai ekstraktor topologi yang membuang semua informasi non-geometris tersebut, menyisakan hanya struktur ludi dari karakter. Hasilnya, model Hybrid Skeleton mencapai akurasi transfer terbaik (11,69%) dengan *domain gap* paling minimum (+66,51%).

B. Pembersihan Derau Topologi Secara Empiris

Salah satu kontribusi kunci penelitian ini adalah pembuktian ilmiah mengenai peran *conditional hole-filling*. Heuristik 7 piksel pada draf terdahulu tidak memiliki dasar teori. Melalui analisis sensitivitas threshold (Tabel IV), kami menunjukkan bahwa batas optimal berada pada 35 piksel. Di bawah 35 piksel, banyak rongga biner halus akibat binerisasi Otsu gagal tertutup, menyebabkan algoritma *skeletonize* menghasilkan loop palsu (*loops* rata-rata 0,85 pada threshold 0). Di atas 35 piksel, proses pengisian mulai menambal lubang struktural bawaan dari huruf (seperti bagian dalam huruf 'A' atau 'B') yang mengakibatkan hilangnya identitas topologi karakter. Nilai 35 piksel menyeimbangkan eliminasi *noise loops* (menjadi 0,36) dengan pelestarian konektivitas garis rangka.

C. Evaluasi Kausal Efisiensi Arsitektur

Melalui eksperimen variabel terkontrol (Tabel III), kami berhasil mengisolasi efek representasi input secara kausal. Akurasi citra *raw* memang tetap menjadi batas atas (*upper bound*) akurasi pada domain yang sama karena kayanya informasi tekstur. Namun, model hybrid menunjukkan bahwa dengan bantuan augmentasi spasial mikro, representasi lidi mampu menghasilkan akurasi yang berselisih sangat tipis (79,10% vs 83,13%) dengan pemotongan kebutuhan parameter jaringan saraf sebesar 74,2%. Konfigurasi filter ramping (16-32-64) pada input skeleton terbukti sangat efisien untuk diimplementasikan pada perangkat tepi karena mengurangi beban memori RAM secara signifikan tanpa mengalami *underfitting* yang parah seperti pada MobileNetV2-tiny.

V. KESIMPULAN

Penelitian ini berhasil merancang dan memvalidasi secara empiris model OCR hybrid alphanumeric berbasis prapemrosesan *skeletonization* dan CNN ringan untuk komputasi tepi. Melalui serangkaian pengujian terstandarisasi, kami membuktikan bahwa: 1. Prapemrosesan *skeletonization* yang dioptimalkan dengan *conditional hole-filling threshold 35 piksel* memberikan representasi geometris terbaik, menekan noise loop topologi dari 0,85 menjadi 0,36, dan menghasilkan akurasi Chars74K sebesar **79,82%**. 2. Model Hybrid Skeleton CNN sangat efisien secara arsitektur (~163.500 parameter) dan mencapai waktu inferensi batch tercepat sebesar **0,19 ms/gambar** (4x lebih cepat dibanding model standar). 3. Pengujian lintas dataset (*Cross-Dataset Validation*) pada EMNIST membuktikan model Hybrid memiliki ketahanan transfer domain terbaik dengan *domain gap* terkecil (+66,51%) dibandingkan model *raw* standard. 4. Analisis latensi sekuensial menunjukkan perbedaan latensi individual dipengaruhi oleh *over-head* graf TensorFlow, namun secara statistik Hybrid Skeleton terbukti signifikan lebih cepat dibanding MobileNetV2-tiny ($p < 0,01$).

Riset masa depan disarankan untuk mengeksplorasi integrasi normalisasi ukuran garis otomatis sebelum penipisan guna meminimalisasi efek distorsi spasial pada resolusi tinggi.

REFERENCES

- [1] T. Y. Zhang and C. Y. Suen, "A fast parallel algorithm for thinning digital patterns," *Communications of the ACM*, vol. 27, no. 3, pp. 236–239, 1984.
- [2] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [4] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *International Conference on Learning Representations (ICLR)*, 2015.
- [5] O. S. Parulian, "Efficient Design and Compression of CNN Models for Rapid Character Recognition," *Jurnal Ilmu Komputer dan Informasi*, vol. 18, no. 1, Feb. 2025.
- [6] R. N. Khobragade, N. A. Koli, and M. S. Makesar, "Evaluations of Thinning Algorithms for Preprocessing of Handwritten Characters," *International Journal on Recent and Innovation Trends in Computing and Communication*, vol. 2, no. 11, pp. 3759–3761, Nov. 2014.
- [7] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, "Edge Computing: Vision and Challenges," Technical Report: MIST-TR-2015-008, Wayne State University, 2015.

- [8] T. E. de Campos, B. R. Babu, and M. Varma, "Character recognition in natural images," in *Proceedings of the International Conference on Computer Vision Theory and Applications (VISAPP)*, Lisbon, Portugal, Feb. 2009.
- [9] D. Shi, X. Diao, H. Tang, X. Li, H. Xing, and H. Xu, "RCRN: Real-world Character Image Restoration Network via Skeleton Extraction," in *Proceedings of the 30th ACM International Conference on Multimedia*, Oct. 2022, pp. 1177–1185.
- [10] G. Cohen, S. Afshar, J. Tapson, and A. van Schaik, "EMNIST: Extending MNIST to handwritten letters," in *Proceedings of the International Joint Conference on Neural Networks (IJCNN)*, 2017, pp. 2921–2926.