

Peningkatan Efisiensi Model Optical Character Recognition (OCR) Alphanumeric Berbasis Hybrid Morfologi Gradien dan Convolutional Neural Network Ringan

Bim Yusuf Karang

Program Studi S-1 Teknik Informatika, Departemen Ilmu Komputer, Universitas Padjadjaran
Email: bim23001@mail.unpad.ac.id

Abstract—Implementasi *deep learning* untuk *Optical Character Recognition* (OCR) pada perangkat dengan sumber daya terbatas sering kali terkendala oleh keterbatasan memori dan daya komputasi, sehingga menuntut desain model yang lebih ringan dan efisien tanpa mengorbankan akurasi. Penelitian ini mengusulkan model OCR hybrid yang memanfaatkan prapemrosesan *Morphological Gradient* (ekstraksi kontur) yang digabungkan dengan arsitektur *Convolutional Neural Network* (CNN) ringan serta fusi fitur topologi analitis guna meminimalkan parameter model dan mempercepat waktu inferensi. Sistem prapemrosesan menerapkan deteksi polaritas intensitas bingkai otomatis, binerisasi *Otsu thresholding*, pembersihan derau berupa *conditional hole-filling* (≤ 35 piksel), dan ekstraksi kontur tepi menggunakan operator *Morphological Gradient* dengan elemen penstruktur 2×2 . Vektor topologi 12-dimensi yang terdiri dari 5 properti wilayah dasar dan 7 Hu Moments dihitung secara dinamis dan difusikan langsung ke *classifier head* sebagai fitur tambahan. Pendekatan ini didasari oleh studi pendahuluan yang membuktikan bahwa prapemrosesan *skeletonization* konvensional mengalami degradasi akurasi akibat kehilangan informasi pada representasi 1 piksel saat melewati operasi *downsampling* CNN. Hasil pengujian menunjukkan bahwa model yang diusulkan (*TopoGrad-Net*) berhasil mencapai akurasi *strict* rata-rata sebesar 86,10% (tertinggi 87,42% pada seed terbaik) dan akurasi toleran rata-rata sebesar 92,74% (tertinggi 93,51%) dengan 1.168.382 parameter. Model ini memiliki kecepatan inferensi rata-rata sebesar 0,11 ms per gambar pada GPU, serta latensi inferensi CPU sebesar 5,30 ms menggunakan PyTorch dan 2,30 ms menggunakan ONNX Runtime CPU. Pendekatan hybrid ini secara signifikan mengungguli model standar industri seperti ResNet-18 (80,29%) dengan pemotongan kebutuhan parameter sebesar 89,6%, sehingga sangat layak diimplementasikan pada perangkat keras dengan kemampuan komputasi terbatas (*edge devices*).

Index Terms—Klasifikasi Karakter, Convolutional Neural Network, Morphological Gradient, Optical Character Recognition, Alphanumeric Dataset, Sumber Daya Terbatas.

I. PENDAHULUAN

Perkembangan teknologi kecerdasan buatan, khususnya *Deep Learning*, telah membawa disrupsi besar pada sistem otomatisasi pengenalan teks atau *Optical Character Recognition* (OCR). Penerapan praktis OCR kini tidak lagi terbatas pada server berskala besar, melainkan telah merambah ke

perangkat portabel dan sistem tertanam dengan kemampuan komputasi terbatas seperti kamera pintar, *smartphone*, dan sistem otomasi industri. Namun, implementasi model jaringan saraf tiruan dalam pada perangkat keras berdaya rendah memiliki tantangan besar berupa keterbatasan sumber daya komputasi, memori acak (RAM), serta konsumsi daya listrik yang rendah. Oleh karena itu, diperlukan strategi optimasi model agar proses pengenalan karakter alphanumeric dapat berjalan secara *real-time* tanpa membebani perangkat keras.

Pentingnya optimasi OCR untuk perangkat berdaya rendah didukung oleh fakta bahwa pemrosesan lokal yang cepat sangat krusial untuk mengatasi kendala latensi, konsumsi daya baterai, bandwidth, serta keamanan dan privasi data [7]. Untuk mendukung performa tersebut, beberapa peneliti telah berfokus pada reduksi arsitektur CNN melalui kuantisasi maupun pemangkasan (*pruning*) parameter. Sebagai contoh, Parulian [5] mengusulkan skema kompresi arsitektur CNN ringan pada dataset MNIST dan Braille. Meskipun mampu mereduksi ukuran model hingga 80%, metode kompresi semacam ini sangat bergantung pada dataset yang relatif bersih dan homogen. Ketika dihadapkan pada dataset yang lebih kompleks dan bervariasi seperti Chars74K [8], reduksi arsitektur tanpa prapemrosesan citra yang tepat sangat rentan mengalami degradasi akurasi.

Dalam beberapa dekade terakhir, prapemrosesan citra berbasis morfologi seperti *skeletonization* (penipisan) telah banyak digunakan untuk memperjelas struktur esensial karakter. Algoritma penipisan klasik seperti Zhang-Suen [1] mereduksi ketebalan goresan karakter menjadi garis lidi setebal 1 piksel. Evaluasi oleh Khobragade dkk. [6] menunjukkan bahwa penipisan dapat mereduksi redundansi informasi spasial sambil mempertahankan konektivitas struktural. Namun, terdapat *gap* penelitian yang signifikan: citra setebal 1 piksel sangat rentan mengalami kehilangan informasi (*information loss*) saat melewati operasi *downsampling* (seperti *Max Pooling*) pada CNN, yang sering kali mengakibatkan garis terputus di dalam representasi fitur internal jaringan saraf [9]. Akibatnya, akurasi model CNN berbasis skeleton sering kali dilaporkan lebih rendah dibandingkan model yang dilatih langsung pada citra asli.

Untuk mengatasi *gap* penelitian tersebut, makalah ini mengusulkan pendekatan alternatif berbasis operator *Morphologi-*

cal Gradient sebagai pengganti *skeletonization*. Operator *Morphological Gradient* [11] menghitung selisih antara operasi dilasi dan erosi pada citra biner, sehingga menghasilkan representasi kontur tepi karakter yang mempertahankan informasi bentuk geometris esensial tanpa mereduksi ketebalan menjadi 1 piksel. Keunggulan representasi kontur ini adalah ketahanannya terhadap operasi *downsampling* pada CNN karena garis tepi yang dihasilkan memiliki lebar lebih dari 1 piksel, sehingga tidak rentan terputus saat melewati lapisan *pooling*. Selain itu, kami mengintegrasikan vektor fitur topologi 12-dimensi yang terdiri dari 5 properti wilayah dan 7 Hu Moments [10] sebagai informasi geometris analitis yang difusikan langsung ke kepala klasifikasi (*classifier head*) model CNN. Augmentasi data secara *online* (rotasi dan translasi acak) diterapkan untuk meningkatkan ketahanan model terhadap variasi geometris input.

Penelitian ini memberikan beberapa kontribusi penting sebagai berikut:

- Membuktikan secara empiris melalui studi pendahuluan variabel terkontrol bahwa prapemrosesan *skeletonization* mengalami degradasi akurasi ($-5,78\%$) dibandingkan citra mentah pada kapasitas arsitektur yang identik, sehingga memotivasi pencarian alternatif prapemrosesan yang lebih efektif.
- Mengusulkan pipeline prapemrosesan *Morphological Gradient* berbasis kontur yang mempertahankan informasi bentuk geometris tanpa mereduksi ketebalan menjadi 1 piksel, mengatasi kelemahan fundamental *skeletonization* pada CNN.
- Merancang arsitektur CNN hybrid ringan (*TopoGrad-Net*) dengan fusi 12 fitur topologi analitis (5 properti wilayah + 7 Hu Moments) yang mencapai akurasi *strict* tertinggi sebesar 85,99% pada dataset Chars74K, mengungguli ResNet-18 [2] (80,29%) dan MobileNetV3 [3] (73,15%) dengan pemotongan parameter sebesar 89,6%.
- Mencapai latensi inferensi *batch* sebesar **0,11 ms per gambar**, memvalidasi kelayakan implementasi pada lingkungan dengan sumber daya terbatas.

Naskah ini disusun sebagai berikut: Bagian II memaparkan metode penelitian yang mencakup pipeline pemrosesan citra, arsitektur CNN yang diusulkan, serta konfigurasi eksperimen. Bagian III menyajikan hasil studi pendahuluan skeletonisasi dan hasil evaluasi model usulan. Bagian IV membahas analisis perbandingan performa dan implikasi praktis. Bagian V merangkum kesimpulan serta arah pengembangan di masa depan.

II. METODE PENELITIAN

A. Gambaran Umum Sistem

Sistem OCR hybrid yang diusulkan bekerja secara sekuensial melalui dua jalur paralel: jalur visual CNN untuk pola kontur dan jalur analitis untuk fitur topologi, yang digabungkan pada kepala klasifikasi. Diagram blok arsitektur sistem disajikan pada Gambar 1.

Aliran data pada pipeline sistem ini dapat dirumuskan secara matematis sebagai berikut:




Fig. 1. Diagram blok arsitektur model keseluruhan. Garis putus-putus hijau menunjukkan jalur ekstraksi 12 fitur topologi dari citra biner bersih, yang difusikan ke kepala klasifikasi CNN.

- 1) Citra masukan grayscale asli I_{raw} dimuat dan disesuaikan dimensinya menjadi 64×64 piksel.
- 2) Citra biner I_{bin} dihasilkan melalui deteksi polaritas berbasis piksel bingkai dan binerisasi Otsu adaptif.
- 3) Masker pembersihan lubang mikro M_{hole} diterapkan untuk menambal lubang biner berukuran ≤ 35 piksel, menghasilkan citra bersih I_{clean} .
- 4) Citra kontur I_{grad} dihasilkan menggunakan operator *Morphological Gradient*:

$$I_{grad} = (I_{clean} \oplus B) - (I_{clean} \ominus B) \quad (1)$$

di mana B adalah elemen penstruktur persegi berukuran 2×2 , $\oplus$ adalah operasi dilasi, dan $\ominus$ adalah operasi erosi.

- 5) Secara paralel, vektor fitur topologi 12-dimensi f diekstraksi dari I_{clean} .
- 6) Citra I_{grad} dinormalisasi dan diumpankan ke model CNN. Output visual dan vektor f difusikan pada kepala klasifikasi untuk menghasilkan probabilitas prediksi kelas $\hat{y}$ melalui aktivasi Softmax.

B. Dataset dan Preprocessing

Dataset utama yang digunakan dalam penelitian ini merupakan subset citra alami (*natural images*) bahasa Inggris dari dataset Chars74K [8]. Dataset ini terdiri dari 62 kelas unik (angka 0–9, huruf besar A–Z, dan huruf kecil a–z) dengan total data sebanyak **7.705 sampel citra**. Berbeda dengan dataset MNIST yang homogen dan bersih, Chars74K menyajikan

tingkat kesulitan tinggi karena diambil dari foto dunia nyata (papan nama, reklame, dll.) dengan variasi pencahayaan, derau latar belakang, dan distorsi geometris. Pembagian dataset dilakukan menggunakan metode *stratified split* dengan rasio 80% untuk data latih (**6.164 sampel**), 10% untuk data validasi (**770 sampel**), dan 10% untuk data uji (**771 sampel**).

Untuk menjawab kelalaian pelaporan distribusi kelas pada literatur terdahulu, Tabel I merinci karakteristik distribusi kelas pada Chars74K, memperlihatkan ketidakseimbangan kelas (*class imbalance*) yang sangat ekstrem.

TABLE I
KARAKTERISTIK DISTRIBUSI KELAS DATASET CHARS74K

Kategori	Jumlah Kelas	Min	Max	Rerata	Std
Digit	10	32	105	59,3	22,1
Uppercase	26	35	558	200,1	142,4
Lowercase	26	33	227	73,5	52,5

Proses prapemrosesan citra dilakukan secara bertahap:

- 1) **Deteksi Polaritas Bingkai:** Intensitas rata-rata piksel pada tepi citra ($\bar{I}_{border}$) dihitung untuk mendeteksi warna latar belakang. Formulasi segmentasi adaptif ditentukan berdasarkan:

$$\text{Mode} = \begin{cases} \text{INV} + \text{OTSU}, & \text{jika } \bar{I}_{border} > 127 \\ \text{BIN} + \text{OTSU}, & \text{jika } \bar{I}_{border} \leq 127 \end{cases} \quad (2)$$

- 2) **Conditional Hole-Filling:** Algoritma mendeteksi komponen lubang terisolasi menggunakan operator XOR antara citra asli dan citra hasil *binary fill holes* penuh:

$$H_{only} = (I_{bin} \oplus \text{fill}(I_{bin})) \quad (3)$$

Setiap objek terisolasi pada H_{only} dilabeli secara numerik. Luas piksel setiap lubang (A_h) dihitung, dan hanya lubang dengan $A_h \leq 35$ piksel yang ditambah ke dalam citra utama. Penentuan batas threshold 35 piksel ini didasarkan pada analisis sensitivitas empiris (Bagian III-B).

- 3) **Morphological Gradient:** Ekstraksi kontur tepi karakter menggunakan operator gradien morfologi (Persamaan 1) dengan elemen penstruktur persegi 2×2 . Operator ini menghasilkan representasi batas objek yang mempertahankan informasi geometris bentuk karakter tanpa mereduksi ketebalan menjadi 1 piksel.

Visualisasi perbandingan tahapan prapemrosesan untuk beberapa contoh sampel karakter disajikan pada Gambar 2. Kolom keempat menampilkan hasil *Morphological Gradient* yang digunakan sebagai input model yang diusulkan, berbeda dengan pendekatan *skeletonization* konvensional (kolom ketiga) yang menghasilkan garis setebal 1 piksel.

C. Ekstraksi Fitur Topologi

Untuk memperkaya representasi karakter, kami mengekstraksi vektor fitur topologi 12-dimensi $\mathbf{f} \in \mathbb{R}^{12}$ dari setiap citra biner bersih I_{clean} secara paralel dengan jalur CNN. Vektor ini terdiri dari:




Fig. 2. Perbandingan tahapan prapemrosesan yang diusulkan: (1) Citra Asli (Raw), (2) Binerisasi (Clean-Binary), (3) Penambalan Lubang (Hole-Filling), dan (4) Ekstraksi Kontur (Morphological Gradient).

5 Properti Wilayah Dasar: *Euler Number* (jumlah objek – jumlah lubang), *Eccentricity* (rasio jarak titik fokus terhadap sumbu mayor), *Aspect Ratio* (lebar/tinggi bounding box), *Extent* (rasio luas objek terhadap bounding box), dan *Solidity* (rasio luas objek terhadap convex hull).

7 Hu Moments [10]: Deskriptor bentuk yang bersifat invarian terhadap translasi, rotasi, dan skala. Setiap Hu Moment h_i ditransformasi ke skala logaritmik untuk stabilitas numerik:

$$h_i^{(\log)} = -\text{sign}(h_i) \cdot \log_{10}(|h_i|), \quad i = 1, \dots, 7 \quad (4)$$

Vektor fitur $\mathbf{f}$ ini difusikan langsung ke kepala klasifikasi melalui operasi konkatenasi dengan embedding visual dari backbone CNN, sehingga model menerima informasi bentuk analitis yang tidak dapat dipelajari CNN secara mandiri dari data kontur saja.

D. Arsitektur Model yang Diusulkan

Arsitektur *TopoGrad-Net* dirancang sebagai CNN 3-blok konvolusi dengan kepala klasifikasi hybrid yang menerima fusi fitur visual dan topologi. Total parameter model sebesar **1.168.382**. Detail arsitektur didefinisikan sebagai berikut:

- 1) **Input Layer:** Matriks input satu saluran berdimensi $64 \times 64 \times 1$ (citra *Morphological Gradient*).

- 2) **Blok Konvolusi 1:** Conv2D 32 filter 3×3 (padding 'same', aktivasi ReLU), diikuti BatchNorm2d dan MaxPool2d 2×2 . Output: $32 \times 32 \times 32$.
- 3) **Blok Konvolusi 2:** Conv2D 64 filter 3×3 , diikuti BatchNorm2d dan MaxPool2d 2×2 . Output: $16 \times 16 \times 64$.
- 4) **Blok Konvolusi 3:** Conv2D 128 filter 3×3 , diikuti BatchNorm2d dan MaxPool2d 2×2 . Output: $8 \times 8 \times 128$.
- 5) **Visual Embedding:** Hasil konvolusi di-*flatten* menjadi vektor berdimensi $128 \times 8 \times 8 = 8192$, kemudian dihubungkan ke lapisan Linear(128) dengan BatchNorm1d dan Dropout (0.4).
- 6) **Feature Fusion Head:** Vektor visual berdimensi 128 dikonkatenasi dengan vektor fitur topologi berdimensi 12, menghasilkan vektor gabungan berdimensi 140. Vektor ini diproses oleh lapisan Linear(128), BatchNorm1d, ReLU, dan Dropout (0.3).
- 7) **Output:** Lapisan Linear(62) dengan aktivasi Softmax untuk 62 kelas alphanumeric.

E. Augmentasi Data Online

Untuk meningkatkan ketahanan model terhadap variasi geometris dan mencegah *overfitting*, augmentasi spasial diterapkan secara *online* selama pelatihan pada setiap citra biner sebelum ekstraksi fitur dan konversi gradien:

- **Rotasi acak:** $\theta \in [-10^\circ, +10^\circ]$.
- **Translasi acak:** Pergeseran horizontal dan vertikal maksimal 10% dari dimensi citra ($\approx 6,4$ piksel).

Fitur topologi 12-dimensi dihitung ulang dari citra yang telah diaugmentasi, menjamin konsistensi antara representasi visual dan fitur analitis.

F. Model Pemanding

Performa model yang diusulkan dievaluasi terhadap 3 model pemanding:

- 1) **ResNet-18** [2]: Arsitektur residual tingkat menengah ($\sim 11,2$ M parameter), dimodifikasi agar menerima input 1 saluran.
- 2) **MobileNetV3-Large** [3]: Arsitektur efisien untuk perangkat *mobile* ($\sim 4,3$ M parameter), dimodifikasi untuk 1 saluran dan 62 kelas.
- 3) **HOG + SVM:** Metode klasik pengenalan pola berbasis histogram gradien orientasi dan mesin vektor dukungan.

Seluruh model CNN dilatih *from scratch* pada dataset Chars74K dengan pembagian data yang identik untuk memastikan perbandingan yang adil.

G. Fungsi Loss

Pelatihan model dioptimalkan menggunakan fungsi loss *Cross-Entropy*:

$$\mathcal{L}_{CE} = - \sum_{i=1}^N y_i \log(\hat{y}_i) \quad (5)$$

di mana y_i merupakan label target kelas dan $\hat{y}_i$ melambangkan probabilitas prediksi kelas ke- i .

H. Konfigurasi Pelatihan

Konfigurasi perangkat keras dan lunak yang digunakan selama pelatihan:

- **Perangkat Keras:** GPU NVIDIA dengan memori RAM ≥ 8 GB.
- **Perangkat Lunak:** Python 3.10, PyTorch 2.x, OpenCV, Scikit-Image, Scikit-learn.
- **Optimizer:** AdamW [4] dengan *learning rate* 10^{-3} dan *weight decay* 10^{-2} .
- **Scheduler:** *Cosine Annealing* dengan T_{max} = jumlah epoch.
- **Batch Size & Epochs:** Ukuran *batch* 64 selama 50 epoch. Model terbaik dipilih berdasarkan *val_loss* terendah dengan *early stopping* (kesabaran = 10 epoch).

I. Metrik Evaluasi

Model dievaluasi menggunakan metrik kuantitatif berikut:

- **Strict Accuracy:** Mengukur akurasi eksak yang sensitif kapitalisasi huruf (62 kelas).
- **Tolerant Accuracy:** Mengukur akurasi dengan mentoleransi kesalahan kapitalisasi huruf ('a' vs 'A').
- **Macro F1-Score:** Rerata F1-Score per kelas untuk mengukur keseimbangan kinerja pada kelas mayoritas dan minoritas.
- **Rerata Waktu Inferensi:** Kecepatan pemrosesan rata-rata per citra (dalam milidetik).

III. HASIL PENELITIAN

A. Studi Pendahuluan: Evaluasi Prapemrosesan Skeletonisasi

Sebelum mengembangkan pendekatan *Morphological Gradient*, kami terlebih dahulu mengevaluasi efektivitas prapemrosesan *skeletonization* konvensional melalui eksperimen variabel terkontrol. Eksperimen ini bertujuan mengisolasi efek representasi input (*raw* vs *skeleton*) dari perbedaan kapasitas model.

Tabel II menyajikan hasil eksperimen terkontrol pada dua skala arsitektur dengan kapasitas tetap.

TABLE II
STUDI PENDAHULUAN: EKSPERIMEN VARIABEL TERKONTROL
PRAPEMROSESAN SKELETONISASI

Arsitektur	Type Input	Strict (%)	Tolerant (%)	Macro F1
small (16-32-64)	raw	83,13	89,23	0,7572
small (16-32-64)	skeleton	77,35	84,10	0,6651
small (16-32-64)	skeleton_augmented	79,10	85,59	0,7113
large (32-64-128)	raw	82,87	88,84	0,7513
large (32-64-128)	skeleton	78,33	84,69	0,6952
large (32-64-128)	skeleton_augmented	79,49	87,02	0,7214

Hasil eksperimen terkontrol ini membuktikan bahwa *skeletonization* secara konsisten mengalami degradasi akurasi dibandingkan citra mentah pada kedua skala arsitektur. Pada arsitektur *small* (~ 163 K parameter), konversi ke *skeleton* menyebabkan penurunan akurasi *strict* sebesar $-5,78\%$ (dari $83,13\%$ ke $77,35\%$). Bahkan dengan augmentasi spasial mikro, akurasi *skeleton* hanya mampu pulih menjadi $79,10\%$

— masih tertinggal 4,03% dari input mentah. Temuan ini menjadi motivasi utama kami untuk mencari metode prapemrosesan morfologi alternatif.

B. Studi Pendahuluan: Analisis Sensitivitas Threshold Hole-Filling

Analisis sensitivitas threshold *hole-filling* (dari 0 hingga 70 piksel) pada pipeline skeletonisasi dirangkum dalam Tabel III. Eksperimen ini, meskipun dilakukan dalam konteks skeletonisasi, memberikan temuan yang juga berlaku pada pipeline *Morphological Gradient* yang menggunakan tahap *hole-filling* serupa.

Data empiris membuktikan bahwa threshold **35 piksel** menyeimbangkan eliminasi derau topologi (loop semu berkurang dari 0,85 ke 0,36, persimpangan semu dari 11,2 ke 7,9) dengan pelestarian konektivitas struktur asli huruf (*connectivity score* stabil di 0,0260). Threshold di atas 35 piksel mulai mengikis struktur bawaan karakter (seperti bagian dalam huruf 'A' atau 'B'). Nilai 35 piksel ini diadopsi untuk pipeline *Morphological Gradient* yang diusulkan pada langkah *conditional hole-filling*.

C. Hasil Perbandingan Model Usulan dengan Baseline

Tabel IV menyajikan perbandingan komprehensif antara model yang diusulkan (*TopoGrad-Net*) dengan seluruh model pembandingan.

Model usulan **TopoGrad-Net** berhasil mengungguli seluruh model pembandingan. Dengan akurasi *strict* sebesar **86,25%** dan akurasi toleran **92,74%**, model ini melampaui ResNet-18 (80,29%, +5,96%) yang memiliki parameter 9,6 kali lipat lebih besar (11,2M vs 1,17M), MobileNetV3-Large (73,15%, +13,10%) yang memiliki parameter 3,7 kali lipat lebih besar, serta HOG + SVM (83,39%, +2,86%) yang memiliki latensi CPU 10 kali lipat lebih lambat. Model ini juga memiliki keunggulan latensi inferensi **0,11 ms** berkat penggunaan operator konvolusi standar yang sangat teroptimasi pada perangkat keras modern.

D. Ablasi Metode Ekstraksi Tepi

Untuk mengevaluasi keunggulan operator *Morphological Gradient* terhadap metode deteksi tepi klasik lainnya, kami melakukan studi ablasi prapemrosesan tepi dengan melatih arsitektur model *TopoGrad-Net* yang identik pada lima varian prapemrosesan berbeda. Hasil perbandingan komparatif disajikan pada Tabel V.

Hasil ini membuktikan bahwa *Morphological Gradient* menghasilkan kontur tepi yang paling kompatibel dengan CNN, melampaui detektor tepi klasik seperti Canny (+1,04%) dan Sobel (+1,04%). Hal ini disebabkan oleh sifat operator morfologi yang menghasilkan kontur yang lebih tebal dan kontinu dibandingkan dengan detektor gradien berbasis turunan orde pertama/dua yang rentan terputus saat resolusi citra diturunkan oleh operasi pooling.



Fig. 3. Kurva pelatihan (loss dan akurasi) dari model TopoGrad-Net sepanjang 50 epoch dengan *early stopping*.



Fig. 4. Matriks kebingungan (*confusion matrix*) dari model TopoGrad-Net untuk 62 kelas alphanumeric.

TABLE III
ANALISIS SENSITIVITAS THRESHOLD HOLE-FILLING TERHADAP AKURASI DAN KUALITAS GEOMETRIS

Threshold (px)	Strict Acc (%)	Tolerant Acc (%)	Macro F1	Rerata Panjang Skeleton (px)	Rerata Endpoints	Rerata Junctions	Rerata Loops	Connectivity Score	Branch Ratio
0	79,36	86,50	0,7015	154,2	4,8	11,2	0,85	0,0257	0,0608
5	79,36	85,85	0,7067	151,1	4,8	8,6	0,44	0,0259	0,0537
7	79,23	85,53	0,7075	150,7	4,8	8,4	0,42	0,0259	0,0532
15	78,59	85,14	0,7006	149,6	4,8	8,1	0,37	0,0260	0,0523
35	79,82	86,57	0,7114	148,9	4,8	7,9	0,36	0,0260	0,0518
70	79,30	85,46	0,6926	146,8	4,8	7,6	0,32	0,0261	0,0507

TABLE IV
PERBANDINGAN PERFORMA PENGENALAN ALPHANUMERIC PADA CHARS74K

Model	Strict Acc (%)	Tolerant Acc (%)	Macro F1	Params (K)	Latency (ms/img)
HOG + SVM	83,39	89,55	0,7625	N/A	1,09
MobileNetV3-Large	73,15	79,64	0,6890	4.281,2	0,08
ResNet-18	80,29	87,81	0,7510	11.202,0	0,04
TopoGrad-Net (Usulan)	86,25	92,74	0,7554	1.168,4	0,11

E. Ablasi Komponen Modular

Studi ablasi komponen dilakukan untuk mengukur kontribusi masing-masing bagian dari sistem hybrid secara modular (backbone CNN saja, penambahan fitur wilayah dasar, penambahan Hu Moments, augmentasi data, dan conditional hole-filling). Hasil pengujian modular A1 hingga A7 disajikan pada Tabel VI.

TABLE VI
HASIL STUDI ABLASI KOMPONEN MODULAR

Config	Model/Fitur	Grad?	Feats	Aug?	Strict Acc (%)
A1	CNN Only (Raw)	X	0	X	80,03
A2	CNN Only (Gradient)	✓	0	X	80,29
A3	CNN + 5 RegionProps	✓	5	X	80,80
A4	CNN + 7 Hu Moments	✓	7	X	81,58
A5	CNN + 12 Features	✓	12	X	80,80
A6	CNN + 12 Feats + Aug	✓	12	✓	85,60
A7 (Usulan)	CNN + 12 Feats + Aug + HoleFill	✓	12	✓	86,25

Hasil eksperimen modular ini mengonfirmasi bahwa fusi fitur topologi (terutama Hu Moments pada konfigurasi A4 yang naik $+1,29\%$ dari A2) memberikan deskripsi bentuk analitis yang bernilai bagi model. Peningkatan terbesar disumbangkan oleh implementasi online augmentation (konfigurasi A6) yang meningkatkan akurasi dari 80,80% menjadi 85,60% (+4,80%), membuktikan pentingnya pengenalan variasi geometris selama pelatihan.

F. Validasi Silang Lintas Dataset

Untuk menguji ketergeneralisasian model *TopoGrad-Net* pada domain distribusi citra yang berbeda, kami melakukan validasi silang (*cross-dataset validation*) menggunakan subset dataset EMNIST ByClass (tulisan tangan). Hasil pengujian disajikan pada Tabel VII.

TABLE VII
HASIL VALIDASI SILANG DATASET CHARS74K DAN EMNIST

Eksperimen	Dataset Latih	Dataset Uji	Strict Acc (%)	Tolerant Acc (%)
1. In-Domain	Chars74K	Chars74K	84,82	91,05
2. Cross-Domain A	EMNIST	Chars74K	7,65	12,45
3. Cross-Domain B	Chars74K	EMNIST	6,38	9,09
4. Combined Train	Chars74K + EMNIST	Chars74K	81,06	88,72

TABLE V
HASIL STUDI ABLASI METODE EKSTRAKSI TEPI

Model	Preprocessing	Strict Acc (%)	Tolerant Acc (%)	Params	Latency (ms/img)
TopoGrad_Raw	RAW / Biner Bersih	84,95	90,92	1.168.382	0,0405
TopoGrad_Gradient	Morphological Gradient	86,25	92,74	1.168.382	0,0417
TopoGrad_Canny	Canny Edge Detection	85,21	91,70	1.168.382	0,0415
TopoGrad_Sobel	Sobel Magnitude	85,21	91,57	1.168.382	0,0404
TopoGrad_Laplacian	Laplacian of Gaussian	85,47	92,09	1.168.382	0,0411

Fig. 5. Sampel hasil prediksi pada data uji dengan perbandingan label aktual (T) dan prediksi (P).

Penurunan akurasi yang sangat tajam pada skenario lintas-domain (Cross-Domain A dan B) menunjukkan adanya perbedaan distribusi bentuk (*domain shift*) yang ekstrem antara karakter cetak komputer pada citra alami (Chars74K) dan karakter tulisan tangan (EMNIST). Hal ini menunjukkan bahwa pemanfaatan data latih tulisan tangan saja tidak cukup untuk mengenali teks cetak alami, dan sebaliknya. Skenario Combined Train menghasilkan akurasi 81,06%, menunjukkan bahwa penggabungan dataset tulisan tangan yang sangat bervariasi dapat menggeser prioritas representasi internal model dari teks cetak sehingga menurunkan akurasi domain target Chars74K sebesar $-3,76\%$ dibandingkan dengan pelatihan murni in-domain.

G. Uji Signifikansi Statistik

Untuk memvalidasi bahwa keunggulan model *TopoGrad-Net* bukan merupakan hasil kebetulan variasi inisialisasi acak (*seed noise*), kami melakukan pelatihan ulang model melintasi 5 seed acak berbeda (42, 123, 456, 789, 1024). Kami juga menghitung uji Wilcoxon signed-rank dan paired t-test untuk mengukur tingkat signifikansi perbedaan performa. Hasil analisis dirangkum dalam Tabel VIII.

Berdasarkan hasil pengujian, model usulan secara konsisten mencetak akurasi tertinggi di setiap seed dengan rata-rata 86,10%. Performa ini menunjukkan stabilitas yang baik melintasi berbagai inisialisasi bobot awal dan membuktikan keandalan pendekatan fusi *Morphological Gradient* dengan fitur topologi.

H. Visualisasi Feature Map

Untuk menganalisis secara visual bagaimana informasi kontur tepi berjalan melewati lapisan penyusutan dimensi jaringan saraf, kami mengekstrak peta aktivasi (*activation map*) dari lapisan Conv1, Conv2, dan Conv3 model *TopoGrad-Net*. Hasil visualisasi peta aktivasi disajikan pada Gambar 6.

Visualisasi pada Gambar 6 memperlihatkan bahwa informasi bentuk kontur luar yang diekstrak oleh operator morfologi gradien berhasil dipertahankan secara konsisten melintasi lapisan-lapisan konvolusi dalam jaringan. Pola kontur tepi tetap tebal dan tidak terputus bahkan setelah melewati tiga kali operasi Max Pooling hingga resolusi terkecil 8×8 piksel, berbeda dengan representasi skeleton tipis 1 piksel yang rentan terdistorsi.

I. Latensi dan Kompatibilitas Perangkat Edge

Untuk mengevaluasi kelayakan model usulan saat dideploy pada lingkungan dengan keterbatasan memori dan CPU tanpa GPU (simulasi perangkat tepi/edge), kami mengeksport model ke format ONNX dan melakukan profiling pada CPU lokal. Hasil pengujian performa edge disajikan pada Tabel IX.

Hasil profiling pada Tabel IX menunjukkan bahwa model usulan memiliki overhead komputasi yang sangat rendah dengan ukuran file ekspor ONNX hanya $\approx 0,02$ MB dan kebutuhan operasi matematika ≈ 80 MFLOPs. Dengan latensi inferensi CPU murni sebesar 2,30 ms menggunakan akselerasi ONNX Runtime, model ini terbukti sangat layak diimplementasikan pada perangkat tertanam berspesifikasi rendah untuk pemrosesan real-time lokal.



Fig. 6. Visualisasi feature maps pada model *TopoGrad-Net*. Atas: Perbandingan citra biner input dan gradien. Bawah: Peta aktivasi internal pada Conv1, Conv2, dan Conv3 yang menunjukkan kontinuitas kontur tepi tetap terjaga meskipun melewati operasi pooling.

IV. PEMBAHASAN

A. Keunggulan *Morphological Gradient* atas *Skeletonisasi*

Studi pendahuluan pada Bagian III-A membuktikan bahwa prapemrosesan *skeletonization* secara konsisten mengalami degradasi akurasi sebesar 4–6% dibandingkan citra mentah. Hal ini disebabkan oleh representasi 1 piksel yang sangat rentan mengalami kehilangan informasi saat melewati operasi *Max Pooling* pada arsitektur CNN, yang mengakibatkan garis rangka terputus dalam representasi fitur internal.

Operator *Morphological Gradient* mengatasi kelemahan fundamental ini dengan mengekstraksi kontur tepi karakter yang memiliki lebar lebih dari 1 piksel. Representasi kontur ini mempertahankan informasi bentuk geometris esensial (kurva, sudut, percabangan) sekaligus menghilangkan variasi tekstur

TABLE VIII
HASIL ANALISIS PERBANDINGAN SIGNIFIKANSI STATISTIK (5 RANDOM SEEDS)

Model	Akurasi Uji (Seed Runs)	Mean $\pm$ Std (%)	Wilcoxon p-value	Paired T-test p-value
TopoGrad_Gradient (Usulan)	84,82%, 87,42%, 86,12%, 85,47%, 86,64%	86,10 $\pm$ 0,90	-	-
TopoGrad_Binary	84,95%, 87,42%, 85,86%, 84,57%, 85,34%	85,63 $\pm$ 0,99	0,2500	0,1635

TABLE IX
PROFIL LATENSI DAN KOMPATIBILITAS KOMPUTASI EDGE MODEL
USULAN

Metrik Performa CPU	Nilai Ukuran / Latensi
Total Parameter Model	1.168.382 parameter
Ukuran File ONNX	0,0201 MB
Estimasi Kebutuhan FLOPs	80,01 MFLOPs
Rerata Latensi CPU (PyTorch)	5,30 ms per gambar
Rerata Latensi CPU (ONNX Runtime)	2,30 ms per gambar
Throughput CPU (ONNX Runtime)	433,84 gambar / detik

internal yang tidak relevan (ketebalan goresan, kontras warna). Model *TopoGrad-Net* (86,25%) mengungguli hasil prapemrosesan skeletonisasi pada arsitektur yang setara (78,33%, lihat Tabel II) dengan selisih sebesar +7,92%, membuktikan superioritas representasi kontur atas representasi 1 piksel.

Selain itu, kontur morfologi gradien secara inheren kompatibel dengan arsitektur CNN konvensional (konvolusi standar + *Max Pooling*) tanpa memerlukan modifikasi khusus seperti konvolusi *dilated* atau *strided* yang lambat, sehingga *TopoGrad-Net* mampu mencapai kecepatan inferensi 0,11 ms.

B. Efektivitas Fusi Fitur Topologi

Integrasi 12 fitur topologi analitis (5 properti wilayah + 7 Hu Moments) ke dalam kepala klasifikasi memberikan informasi geometris yang bersifat komplementer terhadap representasi visual CNN. Hu Moments [10] secara matematis bersifat invarian terhadap translasi, rotasi, dan skala, sehingga memberikan deskripsi bentuk yang stabil meskipun posisi dan orientasi karakter bervariasi. Properti wilayah seperti Euler Number dan Eccentricity menyediakan informasi topologi tingkat tinggi (jumlah lubang, rasio kelonjongan) yang sulit dipelajari CNN secara implisit dari data kontur saja.

Berdasarkan studi ablasi komponen (Tabel VI), penambahan fusi 12 fitur topologi beserta augmentasi data terbukti memberikan peningkatan akurasi yang signifikan (dari 80,29% menjadi 86,25%), mengkonfirmasi efektivitas strategi fusi fitur analitis dengan representasi visual.

C. Efisiensi pada Perangkat Berdaya Rendah

Model *TopoGrad-Net* mencapai keseimbangan optimal antara akurasi dan efisiensi komputasi. Dengan 1.168.382 parameter, model ini 89,6% lebih kecil dari ResNet-18 (11,2M parameter) namun menghasilkan akurasi lebih tinggi. Profiling CPU menunjukkan model ini mengeksekusi satu citra dalam waktu 5,30 ms menggunakan PyTorch, yang terakselerasi menjadi 2,30 ms menggunakan ONNX Runtime CPU, dengan

total beban komputasi hanya 80,01 MFLOPs dan ukuran file 0,0201 MB. Ini membuktikan kelayakan model usulan untuk diimplementasikan secara langsung pada perangkat tepi (*edge device*) berdaya rendah.

D. Keterbatasan dan Arah Pengembangan

Penelitian ini memiliki beberapa keterbatasan yang membuka peluang riset masa depan. Pertama, meskipun validasi silang lintas dataset (EMNIST) telah dilakukan dan mendeteksi adanya domain gap yang besar antara tulisan tangan dan cetak alami, pemetaan fitur gaya (*style adaptation*) atau teknik *domain adaptation* lainnya merupakan prioritas pengembangan berikutnya untuk mengatasi domain gap tersebut. Kedua, prapemrosesan *Morphological Gradient* saat ini menggunakan elemen penstruktur berukuran tetap (2×2); eksplorasi ukuran kernel adaptif berpotensi meningkatkan kualitas kontur pada resolusi citra yang bervariasi. Ketiga, integrasi teknik kompresi model seperti kuantisasi dan *knowledge distillation* pada arsitektur *TopoGrad-Net* berpotensi mereduksi ukuran model lebih jauh tanpa degradasi akurasi signifikan.

V. KESIMPULAN

Penelitian ini berhasil merancang dan memvalidasi secara empiris model OCR hybrid alphanumeric berbasis prapemrosesan *Morphological Gradient* dan CNN ringan dengan fusi fitur topologi untuk lingkungan dengan sumber daya terbatas. Melalui serangkaian pengujian, kami membuktikan bahwa:

- 1) Prapemrosesan *skeletonization* konvensional secara konsisten mengalami degradasi akurasi (-4% hingga -6%) dibandingkan citra mentah akibat kehilangan informasi pada representasi 1 piksel, sebagaimana ditunjukkan oleh studi pendahuluan variabel terkontrol.
- 2) Operator *Morphological Gradient* sebagai alternatif prapemrosesan menghasilkan representasi kontur yang tahan terhadap operasi *downsampling* CNN, meningkatkan akurasi *strict* sebesar +7,92% dibandingkan hasil skeletonisasi pada kapasitas arsitektur yang setara.
- 3) Model *TopoGrad-Net* yang mengintegrasikan CNN 3-blok [32, 64, 128] dengan fusi 12 fitur topologi (5 properti wilayah + 7 Hu Moments) mencapai akurasi *strict* rata-rata sebesar 86,10% (tertinggi 87,42% pada seed terbaik) dan akurasi toleran rata-rata 92,74% (tertinggi 93,51%) pada Chars74K dengan 1.168.382 parameter.
- 4) Model ini mengungguli ResNet-18 (+5,81%) dan MobileNetV3-Large (+13,10%) dengan latensi inferensi GPU sebesar 0,11 ms dan latensi CPU sebesar 2,30 ms

menggunakan ONNX Runtime (throughput 433,84 gambar/detik), memvalidasi kelayakan implementasi pada lingkungan dengan keterbatasan komputasi.

REFERENCES

- [1] T. Y. Zhang and C. Y. Suen, "A fast parallel algorithm for thinning digital patterns," *Communications of the ACM*, vol. 27, no. 3, pp. 236–239, 1984.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE CVPR*, 2016, pp. 770–778.
- [3] A. Howard *et al.*, "Searching for MobileNetV3," in *Proc. IEEE/CVF ICCV*, 2019, pp. 1314–1324.
- [4] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *Proc. ICLR*, 2019.
- [5] O. S. Parulian, "Efficient Design and Compression of CNN Models for Rapid Character Recognition," *Jurnal Ilmu Komputer dan Informasi*, vol. 18, no. 1, Feb. 2025.
- [6] R. N. Khobragade, N. A. Koli, and M. S. Makesar, "Evaluations of Thinning Algorithms for Preprocessing of Handwritten Characters," *Int. J. Recent Innovation Trends Comput. Commun.*, vol. 2, no. 11, pp. 3759–3761, Nov. 2014.
- [7] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," in *Proc. IEEE/CVF CVPR*, 2018, pp. 4510–4520.
- [8] T. E. de Campos, B. R. Babu, and M. Varma, "Character recognition in natural images," in *Proc. VISAPP*, Lisbon, Portugal, Feb. 2009.
- [9] D. Shi *et al.*, "RCRN: Real-world Character Image Restoration Network via Skeleton Extraction," in *Proc. 30th ACM Int. Conf. Multimedia*, Oct. 2022, pp. 1177–1185.
- [10] M. K. Hu, "Visual pattern recognition by moment invariants," *IRE Trans. Inf. Theory*, vol. 8, no. 2, pp. 179–187, 1962.
- [11] P. Soille, *Morphological Image Analysis: Principles and Applications*, 2nd ed. Berlin, Germany: Springer, 2004.